



Московский государственный университет им. М.В. Ломоносова

Факультет вычислительной математики и кибернетики

Кафедра математических методов прогнозирования

Отчёт по лабораторной работе № 1

"Обработка изображений"

Студент 3го курса группы 317
Абдраманов Равиль

Москва
Март 2026

Содержание

1	Постановка задачи	2
2	Описание данных	2
3	Описание метода решения	3
3.1	Предобработка изображений	4
3.2	Сегментация с помощью SAM	5
3.3	Постобработка масок	6
3.4	Классификация объектов	8
3.5	Распознавание букв	11
4	Описание программной реализации	13
5	Эксперименты	14
6	Выводы	16
	Список литературы	16

1 Постановка задачи

В рамках лабораторной работы №1 ставилась задача разработки программы для автоматического подсчета объектов определенного типа на изображениях.

Входными данными служат цифровые фотографии в формате RGBc различными условиями съемки: неоднородное освещение, наличие теней и бликов, различные типы фоновых подложек. Программа должна функционировать в интерактивном диалоговом режиме, обеспечивая пользователю возможность выбора файла, визуализации промежуточных этапов обработки и вывода итоговой статистики.

Задание предусматривает три уровня сложности, определяемых характеристиками фона и освещения. Уровень Beginner включает изображения с простым фоном и равномерным светом. Уровень Intermediate характеризуется сложными текстурами подложки и наличием выраженных теней. Уровень Expert является расширенным и требует дополнительного распознавания символов латинского алфавита, составленных из групп объектов.

Работа системы считается успешной, если она корректно сегментирует и классифицирует объекты на тестовых выборках всех трёх уровней сложности, обеспечивая минимальное количество ложных срабатываний и пропусков целевых объектов. Особое внимание уделяется устойчивости алгоритма к вариациям освещения и наличию теней.

2 Описание данных

Набор данных состоит из 13 изображений в формате JPG, содержащих объекты трёх классов: перепелиные яйца, красные помидоры черри и желтые (оранжевые) помидоры черри. Каждый класс объектов обладает уникальным набором визуальных признаков. Перепелиные яйца характеризуются овальной формой, неоднородной пятнистой текстурой поверхности и светло-бежевым основным цветом. Красные помидоры имеют форму, близкую к сфере, и насыщенный бордовый оттенок с гладкой поверхностью. Желтые помидоры аналогичны красным по форме и текстуре, но отличаются желто-оранжевым цветовым спектром.



(a) Beginner



(b) Intermediate



(c) Expert

Рис. 1: Примеры изображений из обучающей выборки.

Также исходные изображения характеризуются разнообразием условий съёмки. Фоновые подложки представлены как однотонными поверхностями, так и текстурированными, включая клетчатые ткани, что усложняет задачу отделения объектов от фона. Освещение на снимках неоднородное, присутствуют как мягкие тени, так и яркие блики. Объекты в кадре могут частично касаться друг друга, что создаёт дополнительные трудности при сегментации. На некоторых изображениях объекты (яйца и помидоры) формируют контуры букв латинского алфавита, что требует не только сегментации отдельных объектов, но и восстановления их пространной конфигурации для последующего распознавания символа.

На рисунке 1 представлены примеры изображений для каждого класса сложности. Можно увидеть, что изображение класса Beginner имеет однородный фон, все целевые объекты расположены на достаточном для их сегментации расстоянии друг от друга, тени имеют низкую контрастность по сравнению с объектами, а все объекты имеют четкий цвет и другие, присущие им признаки. Однако в классе Intermediate все меняется, наблюдаются большие контрастные тени, по размерам превосходящие сами объекты, контрастный, текстурный и яркий фон, а также половинчатое затемнение перепелиных яиц, усложняющее процесс сегментации. Картинкам класса Expert также присущи проблемы с неоднородностью фона, однако не такие сильные, но сама задача усложняется дополнительным заданием распознавания буквы.

Все изображения представлены в цветовой модели RGB с глубиной цвета 8 бит на канал. Общее количество объектов в выборке варьируется от кадра к кадру, что требует от алгоритма адаптивности к плотности сцены.

3 Описание метода решения

Разработанный метод обработки изображений представляет собой конвейер, состоящий из четырёх последовательных этапов: предобработка, сегментация, постобработка масок и классификация объектов. Для уровня сложности Expert конвейер дополняется модулем реконструкции символа и его распознавания. Каждый этап был спроектирован с учётом ограничений используемых алгоритмов и специфики входных данных. На рисунке 2 представлена схема работы нашей программы. Подробное описание каждого этапа представлено в соответствующем подразделе.



Рис. 2: Схема работы модели подсчета целевых объектов и распознавания символа.

3.1 Предобработка изображений

Этап предобработки был важен для корректной работы нейросетевого сегментатора Segment Anything Model (SAM). Архитектура SAM чувствительна к контрасту границ и равномерности освещения, модель склонна пропускать объекты со слабовыраженными краями или сегментировать тени как отдельные объекты при неравномерном освещении. Исходя из этих требований, была проведена специальная процедура улучшения изображения.

Обработка начинается с преобразования изображения из цветового пространства RGB в LAB. Данный выбор обусловлен тем, что в пространстве LAB канал яркости L отделён от цветовой информации (каналы A и B), что позволяет корректировать освещённость, не искажая цвета объектов, что важно для последующей классификации. Для устранения теней применяется нелинейное логарифмическое преобразование канала яркости:

$$L_{\text{new}} = \frac{\ln(1 + L_{\text{old}} \cdot \alpha)}{\ln(1 + \alpha)}, \quad \alpha = 10. \quad (1)$$

Использование логарифмической функции, а не линейного масштабирования, позволяет поднять яркость в затенённых областях, сохраняя при этом детали в уже освещённых участках и избегая пересвета (насыщения пикселей единицей). Далее применяется операция усиления границ, заключающаяся в вычитании размытой версии изображения из оригинала с коэффициентом усиления $k = 1.5$. Это повышает высокочастотную составляющую сигнала, делая контуры объектов более чёткими для детектора границ внутри SAM. После усиления границ возможно проявление импульсного шума, который подавляется медианным фильтром с ядром 3×3 . Завершает этап предобработки применение адаптивного выравнивания гистограммы (CLAHN) к каналу L , что обеспечивает локальное улучшение контраста без глобального усиления шума на однородных фонах.




Рис. 3: Примеры предобработки изображений: слева — исходные изображения, справа — результат применения предобработки (логарифмическое осветление теней, усиление границ, медианная фильтрация и CLAHN)

На рис. 3 приведены примеры результатов предобработки для изображений разных уровней сложности. Для изображения уровня Beginner применение методов осветления и выравнивания гистограммы позволило эффективно устранить тени:

тёмные участки стали значительно светлее, а цветовые искажения сведены к минимальным зеленовато-жёлтым малоконтрастным пятнам, которые не должны сильно повлиять на сегментацию. Однако для изображения уровня Intermediate все протекает не так гладко. На самом изображении тени - высококонтрастные эллипсы, насыщенность которых превышает насыщенность целевых объектов. Полное устранение таких теней трудноосуществимо без потери важных для сегментации деталей. Тем не менее данный метод предобработки позволил сблизить цветовые характеристики теней с фоном, в результате чего понижается вероятность того, что нейросеть SAM проинтерпретирует тени как самостоятельные объекты, тем самым повышая качество последующей сегментации.

3.2 Сегментация с помощью SAM

Для решения задачи первичной сегментации выбрана нейросетевая модель **Segment Anything Model (SAM)** [1], разработанная исследовательской группой Meta AI. Особый интерес представляет тот факт, что одним из ведущих авторов модели и первым автором статьи является Александр Кириллов — выпускник и бывший студент кафедры ММП факультета ВМК МГУ, работавший под научным руководством профессора Д.П. Ветрова.

Архитектура SAM состоит из трёх основных компонент:

1. Кодировщик изображений — тяжёлая трансформер-сеть, которая один раз обрабатывает входное изображение и создаёт его векторное представление. Этот этап выполняется один раз для каждого изображения.
2. Кодировщик промптов — кодирует пользовательские указания (точки, рамки или маски) в векторное пространство.
3. Декодер масок — легковесный модуль, который объединяет векторное представление изображения и промпты для генерации финальной бинарной маски сегментации.

Уникальность SAM заключается в её способности к обобщению: модель обучена на огромном датасете SA-1B (более 1 млрд масок) и может сегментировать любые объекты, даже те, которые она не встречала в процессе обучения, основываясь лишь на геометрических и текстурных признаках.

В данной работе модель используется в режиме автоматической генерации масок. В этом режиме алгоритм самостоятельно формирует плотную сетку точек-промптов по всему изображению, передаёт их в декодер и получает множество вариантов сегментации для каждой точки. Затем производится постобработка: маски с низким качеством предсказания отфильтровываются, а оставшиеся объединяются через операцию Non-Maximum Suppression для устранения дубликатов.

Для достижения полноты обнаружения целевых объектов и во избежание приобретения шумовых артефактов в качестве масок экспериментально были подобраны параметры генератора масок, речь о которых идет далее. Плотность сетки точек - 32 (1024 точек-промптов), для достаточного покрытия всего кадра без избыточных вычислений. В качестве порога уверенности модели выбрано число 0.88, по той причине, что почти для всех целевых объектов модель обладала более чем 90 % -ой уверенностью. Также в SAM присутствует так называемый порог устойчивости. Модель проверяет стабильность маски при малых сдвигах порога бинаризации, в качестве

значения для порога устойчивости было выбрано число 0.93. К тому же было выставлено ограничение на минимальную площадь маски в пикселях в качестве 2000, позволяющее игнорировать мелкий текстурированный шум фона (к примеру небольшие контрастные квадраты на изображении 1b).

Данный набор параметров позволяет получить качественный набор кандидатов, который далее подвергается постобработке, описанной в следующем разделе.

3.3 Постобработка масок

Первичные маски, сгенерированные моделью SAM, требуют дополнительной обработки для устранения типичных артефактов сегментации: фрагментации объектов, ложных срабатываний на текстурах фона и включения теней. Для этого разработан целый конвейер постобработки, применяющий последовательность геометрических и цветовых фильтров.

На первом этапе выполняется грубая фильтрация по площади и положению. Исключаются маски, занимающие более 30% площади изображения (вероятные фрагменты фона), а также объекты, покрывающие более 70% любой из границ кадра. Последний критерий эффективно удаляет фоновые текстуры, прилегающие к краям, но сохраняет целевые объекты, случайно оказавшиеся у границы изображения.

Далее применяется грубая адаптивная фильтрация по размеру. Объекты, площадь которых отличается от медианной площади всех detected объектов более чем в 2.5 раза (как в большую, так и в меньшую сторону), помечаются как кандидаты на удаление. Однако, чтобы избежать потери крупных или мелких целевых объектов, вводится исключение: если объект обладает высокой круглостью ($Circularity > 0.8$), то он не отсеивается:

$$Circularity = \frac{4\pi S_{obj}}{P_{obj}^2}, \quad (2)$$

Для устранения фрагментации (разбиения одного объекта на части) применяется слияние близких масок. Критерием объединения служит увеличение у слившейся фигуры коэффициента выпуклости (Solidity):

$$Solidity = \frac{S_{obj}}{S_{hull}}, \quad (3)$$

где S_{obj} — площадь маски, S_{hull} — площадь её выпуклой оболочки. Если объединение двух масок - фигура более выпуклая, чем оба объекта по отдельности, то объекты сливаются в один.

Дополнительно применяется преобразование улучшающее качество масок, маски заменяются на их выпуклые оболочки для стабилизации их формы.

Далее происходит второй, более строгий проход адаптивной фильтрации по размеру. Пороговые значения ужесточаются: теперь удаляются объекты, площадь которых превышает медианную более чем в 1.4 раза или меньше её в 5 раз. Необходимость повторной фильтрации обусловлена сдвигом медианы площадей после первого этапа очистки. На начальном этапе наличие большого количества шумовых масок могло существенно исказить значение медианы, делая первый фильтр менее чувствительным. После удаления явного шума медианное значение площади сдвигается, становясь более репрезентативной оценкой размера яиц и помидоров. Это позволяет второму проходу работать более точно и агрессивно отсекавшие оставшиеся артефакты, которые ранее маскировались под нормальные объекты из-за смещенной

статистики. При этом механизм защиты сохраняется: объекты с высокой круглостью не удаляются, даже если их размер выходит за установленные жесткие границы, что гарантирует сохранность всех нужных объектов.




Рис. 4: Примеры работы постобработки масок: слева направо — предобработанное изображение, первичная сегментация SAM, результат после применения постобработки.

Отдельная группа преобразований отвечает за детекцию и удаление теней. Тенью считается объект, у которого расстояние по цвету до локального фона в пространстве LAB менее 4.5 (то есть объект той же цветовой гаммы, что и фон), а относительная яркость ниже 0.95 (чуть темнее фона). При этом действует правило «иммунитета»: если объект имеет высокую круглость (> 0.8), то он не удаляется,

даже если похож на тень. Дополнительно была введена проверка на вытянутость: вычисляется отношение сторон минимального описанного прямоугольника. Объекты с отношением сторон больше 3.0 отсеиваются, так как тени или текстурные участки фона часто имеют вытянутую форму, в отличие от компактных яиц и помидоров.

На рис. 4 продемонстрированы результаты работы преобразований на изображениях различных уровней сложности.

Для изображения уровня Beginner (рис. 4a) исходная сегментация SAM содержала ошибки фрагментации: некоторые яйца были разделены на светлую и темную части из-за пятнистой текстуры, а также присутствовали ложные маски на тенях. После применения алгоритма слияния разрозненные части объектов были корректно объединены, а тени отфильтрованы по цветовому признаку. К тому же, присутствовали маски, покрывающие сразу несколько других масок, которые были отсеяны с помощью второго прохода адаптивного фильтра по размеру.

На изображении 4b постобработка успешно удалила крупные фоновые артефакты у границ кадра и все тени благодаря комбинации фильтров на вытянутость и цветовое сходство. Однако осталось

В случае сложного изображения (рис. 4c) результаты также улучшились: большая часть теней была устранена. Однако в условиях крайне неравномерного освещения наблюдаются случаи неполной сегментации отдельных яиц (захвачена только часть объекта). Такие артефакты являются следствием низкой контрастности на границах объектов после предобработки и встречаются редко, на данной фотографии их встретилось всего 2 из 16 яиц. Сохранение одного ложного объекта (тени) было осознанным решением: ужесточение порогов постобработки привело бы к потере реальных целевых объектов, что критичнее для итоговой точности классификации. Тем не менее, полученное качество сегментации является достаточным для работы классификатора на следующем этапе.

3.4 Классификация объектов

Для финальной классификации сегментированных объектов выбран ансамбль решающих деревьев **Случайный лес**. Модель конфигурируется со следующими гиперпараметрами: количество деревьев $N_{trees} = 200$, максимальная глубина дерева $D_{max} = 12$. Выбор данного алгоритма обусловлен его высокой устойчивостью к переобучению на малых выборках, что критично в условиях ограниченного размеченного датасета, а также способностью эффективно работать с разнородными признаками без их предварительной нормализации. Помимо этого деревья (компоненты случайного леса), способны достаточно эффективно улавливать нелинейные взаимодействия признаков, что сильно помогает при классификации. Кроме того, метод позволяет получать вероятность принадлежности к классу, что используется для финальной фильтрации сомнительных результатов.

Классификатор обучается распознавать 4 класса - 3 целевых класса и один отвечающий за тени и шум. Последний класс включает в себя разнообразные артефакты сегментации: остатки теней, блики, фрагменты подложки и другие объекты, не относящиеся к целевым объектам.

Также было сконструировано признаковое пространство размерности 18, охватывающее три аспекта визуального восприятия: цвет, текстуру и геометрию. Основное разделение между классами происходит благодаря цвету, однако использование сырых значений RGB недостаточно из-за сильной зависимости значения каналов от

освещения. Поэтому цветовые признаки рассчитываются сразу в трех пространствах. В пространстве RGB используются медианные значения каналов R_{med} , G_{med} , B_{med} , где медиана выбрана вместо среднего арифметического в силу устойчивости к выбросам вроде бликов на помидорах или темных пятен на скорлупе. Признаки из пространства HSV позволяет разделить информацию о цвете и освещенности: канал тона H_{med} критичен для различения красных и желтых объектов, тогда как насыщенность S_{med} и яркость V_{med} помогают отсеять серые тени. И более точную информацию обеспечивает пространство LAB, приближенное к равномерному восприятию цвета человеческим глазом: каналы A_{med} (зелено-красная ось) и B_{med} (сине-желтая ось) достаточно хороши для определения характерных оттенков помидоров.

Для усиления разделяющей способности и компенсации глобальных изменений освещения были введены также признаки, значение которых зависит от фона. Цветовой индекс представляет собой отношение красного канала к зеленому $RG_{ratio} = R_{med}/(G_{med} + \varepsilon)$, которое резко возрастает для красных объектов. Более сложные метрики вычисляются как отклонения характеристик объекта от характеристик его непосредственного окружения (кольца вокруг маски): разность цветовых индексов RG_{diff_bg} , отношение яркостей V_{ratio_bg} и разность насыщенностей S_{diff_bg} . Такие признаки делают классификатор менее зависимым от условий съемки, так как он анализирует не абсолютные значения цвета, а характеристики объекта относительно фона.

Текстурные признаки необходимы для разделения классов, имеющих схожий цвет, но разную поверхность, например, перепелиные яйца отличаются характерной пятнистой текстурой, тогда как помидоры черри обычно гладкие. Для кодирования этой информации вычисляется стандартное отклонение яркости σ_{val} внутри маски, где высокое значение указывает на наличие контрастных пятен, а низкое — на однородность. Дополнительным индикатором служит энергия градиента E_{grad} , вычисляемая через оператор Собеля [2] как средняя величина градиента яркости внутри объекта. Этот признак чувствителен к мелким деталям текстуры скорлупы, которые не улавливает простое стандартное отклонение, и позволяет отличать шероховатую поверхность яиц от блика на помидоре, несмотря на то что обе эти поверхности имеют высокое стандартное отклонение.

Геометрические признаки учитывают форму объектов, яйца имеют вытянутую эллипсоидную форму, а помидоры стремятся к сфере. Помимо абсолютной площади S , используемой для первичного отсева шума, ключевыми признаками являются коэффициенты круглости и выпуклости, определенные ранее.

Одной из ключевых проблем при обучении являлся малый объем данных, поэтому для повышения обобщающей способности модели была применена стратегия аугментации в пространстве признаков. В отличие от традиционной аугментации изображений (повороты, отражения), в данной работе используется шумовая аугментация векторов признаков: исходный датасет расширяется в 30 раз путем генерации синтетических примеров, где каждый признак x_k искажается аддитивным гауссовым шумом $\xi \sim \mathcal{N}(0, 0.05 \cdot \sigma_k)$. Такой подход выбран по ряду причин. Во-первых, он вычислительно эффективен, так как не требует повторного запуска всего конвейера обработки изображений. Во-вторых, он фокусируется на моделировании основных источников ошибок классификации — небольших колебаний цвета и текстуры из-за шума камеры или изменений освещения, заставляя модель учиться более устойчивым разделяющим границам. В-третьих, этот метод гарантированно сохраняет суть объекта: при агрессивной аугментации изображений можно случайно исказить фор-

му яйца до неузнаваемости, тогда как добавление шума в таблицу признаков лишь слегка сдвигает точку в многомерном пространстве, не меняя её класс.

Для повышения надежности системы вводится механизм пост-фильтрации предсказаний. Random Forest возвращает вектор вероятностей принадлежности к каждому классу, и если максимальная вероятность оказывается ниже порога 0.5, объект считается сомнительным. Такие объекты, скорее всего, являются нетипичными тенями или артефактами сегментации, не похожими ни на один из обучающих классов, поэтому они принудительно переклассифицируются в класс шума и исключаются из финального подсчета.




Рис. 5: Визуализация классификации с подсчетом целевых объектов для всего датасета: бирюзовой линией обведена маска перепелиного яйца, оранжевой линией - маска оранжевого помидора, красной линией - маска красного помидора, а серой линией - маска теней.

На рисунке 5 представлена визуализация работы нашего классификатора-счетчика на обучающем датасете. Было ожидаемо, что точность на обучающих данных будет идеальной, однако она может не полностью отражать обобщающую способность алгоритма на новых, ранее не виденных данных. Основным ограничением обучающей выборки является недостаточное разнообразие фоновых паттернов и

способов освещения сцены. Это создает риск того, что на реальных данных модель может ошибочно классифицировать нетипичную тень как объект класса помидор или яйцо. Как раз таки для уменьшения риска такой ошибки и работает описанная ранее пороговая система отсева объектов по уверенности модели, фильтрующая аномальные объекты.

Работа данной модели на других изображениях будет проиллюстрирована в секции Эксперименты.

3.5 Распознавание букв

Задача требует распознавания букв латинского алфавита, составленных из отдельных объектов. Прямое применение систем распознавания символов к исходному изображению неэффективно из-за высокой разреженности объектов в маске, потому что стандартные алгоритмы ожидают сплошные контуры букв, а не набор изолированных пятен. Для решения этой проблемы проводится предобработка маски изображения, включающая в себя реконструкцию образа буквы на основе сегментированных объектов, после чего применяется нейросетевая модель распознавания букв.

В качестве самой модели распознавания выбрана нейросетевая модель **EasyOCR** [3]. Архитектура системы состоит из двух последовательных модулей. Первый модуль представляет собой детектор текста, который анализирует изображение и выделяет области, вероятно содержащие символы, используя карту уверенности для каждого пикселя. Второй модуль — это модель распознавания на базе рекуррентной нейронной сети с механизмом внимания и декодером, преобразующая выделенные области в символы. Такой подход обеспечивает высокую точность даже при наличии шумов и искажений, однако сильно зависит от качества входного изображения: символы должны быть связными и иметь достаточный контраст. Эти требования не выполняются при прямой подаче масок сегментации.

На первом этапе все маски объектов, которые классификатор отнес к целевым классам, объединяются в единую бинарную маску. Для заполнения промежутков между отдельными яйцами и помидорами, формирующими контур буквы, применяется операция морфологического закрытия с использованием эллиптического структурирующего ядра, размера достаточно большого, чтобы склеить соседние объекты внутри одной буквы, но достаточно малого, чтобы не вызвать слияние разных букв или прилипание к посторонним объектам.

Далее происходит сглаживание полученной бинарной карты гауссовым фильтром с ядром 15×15 , с целью устранения неровностей контура, которые при прямой скелетизации привели бы к образованию множества ложных прямых на скелете. После размытия к изображению применяется алгоритм скелетизации, выделяющий центральную линию буквы толщиной в один пиксель.

Для придания символу формы, привычной для OCR, скелет подвергается геометрической аппроксимации. Контуры скелета аппроксимируются ломаными линиями с допуском $\varepsilon = 0.025 \cdot P$, где P — периметр контура. Это позволяет сгладить мелкие изгибы и выделить основные прямолинейные сегменты буквы. Каждый полученный сегмент затем моделируется на чистом белом фоне с использованием геометрического построения: для отрезка между узлами ломаной строится минимальный описанный прямоугольник, который заполняется черным цветом. Изображение приводится к фиксированному масштабу и толщина линий фиксируется на уровне 25

пикселей, что имитирует стандартный печатный шрифт и устраняет вариативность толщины, вызванную разным размером овощей. После чего изображение дополнительно размывается малым гауссовым ядром 3×3 для сглаживания рванности, возникающей при переходе к новой размерности.

Финальная подготовка изображения для детектора включает добавление белых полей шириной 200 пикселей по периметру, чтобы гарантировать попадание всей буквы в рабочую область детектора. Распознавание выполняется с ограничением алфавита заглавными латинскими буквами [A-Z] и включением режима `paragraph=True`, который интерпретирует всю выделенную область как единый символ, повышая точность распознавания одиночных букв большой величины.




Рис. 6: Примеры распознавания букв, слева-направо: оригинальное изображение, маска изображения, сконструированная буква (подпись - распознанная моделью буквы).

На рис. 6 продемонстрированы результаты работы алгоритма реконструкции и распознавания на двух изображениях уровня Expert. При анализе второго примера можно заметить утолщение контура в области пересечения диагональной и вертикальной черт буквы N. Данная особенность реконструкции обусловлена тем, что в области стыковки находятся три близко друг к другу лежащих помидора. При применении операции морфологического замыкания и последующего гауссова размытия сливаются в единый объект увеличенной площади, что искажает идеальную геометрию буквы. Однако модель успешно игнорирует данное искажение толщины, корректно идентифицируя букву, что свидетельствует о высокой устойчивости предложенного метода к небольшим дефектам реконструкции.

4 Описание программной реализации

Программа разработана на языке Python 3.10 и представляет собой модульное приложение с графическим интерфейсом, созданным на базе библиотеки Tkinter. Архитектура решения разделяет вычислительную логику и пользовательский интерфейс: весь алгоритмический код инкапсулирован в модуле `logic.py`, а управление взаимодействием с пользователем реализовано в модуле `main.py`.

Для реализации алгоритмов были использованы следующие библиотеки: **OpenCV** выполняет низкоуровневые операции обработки изображений, включая цветовые преобразования, морфологические фильтры и вычисление геометрических характеристик контуров; фреймворк **PyTorch** совместно с моделью **Segment Anything (SAM)** отвечает за нейросетевую сегментацию; библиотека **Scikit-learn** реализует классификатор Random Forest, а **EasyOCR** используется для распознавания символов на уровне Expert. Вспомогательные вычисления с массивами данных выполняются средствами **NumPy** и **Pandas**.

Модуль `logic.py` содержит ключевые функции конвейера обработки. При старте программы функция инициализации единожды загружает тяжелые модели в память устройства, что исключает задержки при последующем анализе.




Рис. 7: Главное окно программы: панель управления слева, область просмотра изображения, панель статистики и всплывающие окна с этапами сегментации и классификации.

Пользовательский интерфейс обеспечивает диалоговый режим работы. Главное окно содержит панель управления для загрузки изображений и запуска анализа, область предпросмотра и блок статистики с подсчетом объектов по классам. Ключевой особенностью реализации является автоматическая визуализация промежуточных этапов: после обработки открываются отдельные окна с бинарными масками сегментации и финальной цветовой разметкой, что позволяет пользователю контролировать корректность работы алгоритма. Для уровня Expert предусмотрен дополнительный вывод распознанного символа и визуализация его скелетонизированного образа. Исходный код программы приведен в приложении. На рисунке 7 приведена визуализация работы разработанной программы.

Для обеспечения комфортного режима диалоговой работы **настоятельно рекомендуется** запускать программу на компьютере с видеокартой производства NVIDIA. Это обусловлено тем, что ключевые компоненты системы — нейросетевой сегментатор и модель распознавания текста — реализованы на фреймворке PyTorch и оптимизированы для параллельных вычислений на графическом процессоре. При наличии GPU время обработки одного изображения составляет всего 1–2 секунды, в случае запуска на CPU время выполнения тех же операций возрастает экспоненциально и может превышать 60 секунд на один файл. Программа автоматически распознает доступное оборудование при старте и выбирает оптимальное устройство для вычислений.

Также к отчету прилагаются все необходимые файлы для установки и запуска программы, а также инструкция по установке.

5 Эксперименты

Для чуть более объективной оценки обобщающей способности разработанного алгоритма и проверки его работы на данных, не входивших в обучающую выборку, был сформирован набор из трех синтетических тестовых изображений. Данные изображения моделируют сложные условия съемки уровня Intermediate и Expert: наличие контрастных фонов со сложной текстурой и близкое расположение объектов друг к другу.




Рис. 8: Результаты классификации на синтетических тестовых изображениях со сложным фоном.

На рис. 8 представлены результаты классификации на трех тестовых сценах. Первое изображение демонстрирует работу алгоритма на контрастном оранжевом фоне с мелкой сетчатой текстурой. Несмотря на то, что цвет подложки близок к оттенкам оранжевых помидоров, а объекты отбрасывают заметные тени, модель корректно сегментировала все яйца и помидоры, не допустив ложных срабатываний на фоне на этапе сегментации.

Второе изображение содержит сцену с большим количеством объектов разного типа, расположенных на сложном полосатом разноцветном фоне. Высокая плотность

объектов и пестрая подложка создавали риск фрагментации масок и ошибок слияния, однако примененный конвейер постобработки успешно справился с разделением соседних объектов и их классификацией. Можно даже увидеть, что яркие полосы после сегментации были отфильтрованы с помощью проверки на вытянутость.

На третьем изображении объекты выложены в форме буквы на сером текстурированном фоне, аналогичном тренировочным данным, но с иной конфигурацией букв и освещением, в результате чего тени стали более контрастными, а сам фон - более четким. Также на данном изображении часть помидоров имеет форму эллипса, в отличие от тренировочного датасета, где в качестве помидоров в основном выступали практически идеальные круги. Однако это не помешало модели хорошо сегментировать данные избавившись от лишних объектов еще до этапа классификации с помощью наших правил постобработки масок.

Во всех трех случаях система продемонстрировала идеальное качество классификации: все целевые объекты были обнаружены, верно отнесены к своим классам, а тени и элементы фона отсеяны.




Рис. 9: Распознавание буквы «К»: слева — исходное изображение, в центре — маска, справа — реконструированная буква.

Отдельно была проведена проверка работоспособности модуля распознавания букв на третьем тестовом изображении, где объекты формируют букву «К». На рис. 9 показан процесс реконструкции символа и результат распознавания. Анализ скелетонизированного образа показал небольшой дефект реконструкции: в нижней правой части буквы отсутствует соединительный элемент, что привело к разрыву контура. Этот артефакт возник из-за неравномерного расстояния между объектами: в некоторых местах помидоры лежат плотно, обеспечивая слияние при морфологическом замыкании, а в других — слишком далеко друг от друга, из-за чего операция закрытия не смогла полностью заполнить зазор. Однако алгоритм распознал букву верно, что свидетельствует о хорошей устойчивости модели EasyOCR к частичным разрывам контуров и вариациям в геометрии исходных данных. Система способна восстанавливать распознаваемую форму символа даже при неидеальной реконструкции.

Таким образом, эксперименты подтвердили, что разработанный метод обладает некоторой устойчивостью к изменению типа фона, наличию теней и вариациям в расположении объектов, успешно решая задачи всех трех уровней сложности на данных, не участвовавших в обучении.

6 Выводы

В ходе выполнения лабораторной работы была разработана программа для автоматического поиска, разделения и подсчета перепелиных яиц и помидоров черри на фотографиях. Мы реализовали полный цикл обработки изображений: от улучшения качества картинки и удаления теней до точного выделения объектов нейросетью SAM и определения их типа с помощью алгоритма случайного леса. Программа работает в удобном диалоговом режиме, позволяя пользователю загружать изображения, видеть все промежуточные этапы работы и получать готовую статистику.

Решение успешно справляется с заданиями всех трех уровней сложности. На простых и средних изображениях программа точно считает объекты, игнорируя сложный фон и тени. Для самого сложного уровня Expert был добавлен алгоритм распознавания букв, составленных из овощей, который показал надежность работы даже при неидеальном расположении объектов. Тестирование на новых данных подтвердило, что метод работает относительно устойчиво и дает правильные результаты. Таким образом, цель лабораторной работы достигнута в полном объеме: создан работающий программный продукт, готовый к демонстрации и использованию.

Список литературы

- [1] Alexander Kirillov, Eric Mintun, Nikhila Ravi, and Mao e.t.c. Segment anything. *arXiv preprint arXiv:2304.02643*, 2023.
- [2] Ричард Гонсалес, Рафаэль и Вудс. *Цифровая обработка изображений*. Техносфера, Москва, 2006.
- [3] M.A.M. Salehudin, S.N. Basah, and H. Yazid e.t.c. Analysis of optical character recognition using easyocr under image degradation. *Journal of Physics: Conference Series*, 2641(1):012001, 2023.